

## 正则表达式30分钟入门教程

作者: OutMan

日期: 2017-10-08

邮箱: [WHS83@163.COM](mailto:WHS83@163.COM)

转自: [deerchao](#)

版本: v2.21 (2007-8-3)

## 变更记录

\*变更类型: Create、Modify

版本号	变更类型	描述
2007-8-3V2.21	<a href="#">deerchao</a>  Create	2006-3-27 第一版 2006-10-12 第二版 ➤ 修正了几个细节上的错误和不准确的地方 ➤ 增加了对处理中文时的一些说明 ➤ 更改了几个术语的翻译（采用了 MSDN 的翻译方式） ➤ 增加了平衡组的介绍 ➤ 放弃了对 The Regulator 的介绍，改用 Regex Tester 2007-3-12 V2.1 ➤ 修正了几个小的错误 ➤ 增加了对处理选项(RegexOptions)的介绍 2007-5-28 V2.2 ➤ 重新组织了对零宽断言的介绍 ➤ 删除了几个不太合适的示例，添加了几个实用的示例 ➤ 其它一些微小的更改 2007-8-3 V2.21 ➤ 修改了几处文字错误 ➤ 修改/添加了对\$,b 的精确说明 ➤ 承认了作者是个骗子 ➤ 给 RegexTester 添加了 Singleline 选项的相关功能
V2017101501	<a href="#">OutMan</a>  Modify	本文介绍正则表达式的基本知识，在很长的一段时间内我都是将本文作为开发参考手册使用，文章原作者 <a href="#">deerchao</a> 于 10 年前发布，今天 OutMan 重新整理格式并且对部分内容进行了修订

## 目录

1	本文目标.....	1
2	如何使用本教程.....	1
3	正则表达式到底是什么? .....	1
4	入门.....	2
5	测试正则表达式.....	2
6	元字符.....	3
7	字符转义.....	4
8	重复.....	4
9	字符类.....	5
10	反义.....	5
11	替换.....	6
12	分组.....	6
13	后向引用.....	6
14	零宽断言.....	7
15	负向零宽断言.....	8
16	注释.....	9
17	贪婪与懒惰.....	9
18	处理选项.....	10
19	平衡组/递归匹配.....	10
20	还有什么东西没提到.....	12
21	联系作者.....	12
22	一些我认为你可能已经知道的术语的参考字符.....	13
23	网上的资源及本文参考文献.....	13

## 1 本文目标

30 分钟内让你明白“正则表达式”是什么，并对它有一些基本的了解，让你可以在程序里使用它。

## 2 如何使用本教程

重要的是——请给我 30 分钟，如果你没有使用正则表达式的经验，请不要试图在 30 秒内入门。当然，如果你是超人，那自然得另当别论。

别被下面那些复杂的表达式吓倒，只要跟着我一步一步来，你会发现正则表达式其实并没有你想象中的那么困难。当然，如果你看完了这篇教程之后，发现自己明白了很多，却又几乎什么都记不得，那也是很正常的——我认为，没接触过正则表达式的人在看完这篇教程后，能把提到过的语法记住 80% 以上的可能性为零。这里只是让你明白基本的原理，以后你还需要多练习，多使用，才能熟练掌握正则表达式。

除了作为入门教程之外，本文还试图成为可以在日常工作中使用的正则表达式语法参考手册。就作者本人的经历来说，这个目标还是完成得不错的——你看，我自己也没能把所有的东西记下来，不是吗？

文本格式约定：

- 蓝色：专业术语/元字符/语法格式
- 红色：正则表达式
- 绿色：正则表达式中的一部分(用于分析)

## 3 正则表达式到底是什么？

在编写处理字符串的程序或网页时，经常会有查找符合某些复杂规则的字符串的需要。正则表达式就是用于描述这些规则的工具。换句话说，正则表达式就是记录文本规则的代码。

很可能你使用过 Windows/Dos 下用于文件查找的通配符(wildcard)，也就是\*和?。如果你想查找某个目录下的所有的 Word 文档的话，你会搜索\*.doc。在这里，\*会被解释成任意的字符串。和通配符类似，正则表达式也是用来进行文本匹配的工具，只不过比起通配符，它能更精确地描述你的需求——当然，代价就是更复杂——比如你可以编写一个正则表达式，用来查找所有以 0 开头，后面跟着 2-3 个数字，然后是一个连字号“-”，然后是 7 或 8 位数字的字符串(像 010-12345678 或 0376-7654321)。

正则表达式是用于进行文本匹配的工具，所以本文里多次提到了在字符串里搜索/查找，这种说法的意思是在给定的字符串中，寻找与给定的正则表达式相匹配的部分。有可能字符串里有不止一个部分满足给定的正则表达式，这时每一个这样的部分被称为一个匹配。

匹配在本文里可能会有三种意思：一种是形容词性的，比如说一个字符串匹配一个表达式；一种是动词性的，比如说在字符串里匹配正则表达式；还有一种是名词性的，就是刚刚说到的“字符串中满足给定的正则表达式的一部分称为一个匹配”。

## 4 入门

学习正则表达式的好方法是从例子开始，理解例子之后再自己对例子进行修改，实验。下面给出了不少简单的例子，并对它们作了详细的说明。

假设你在一篇英文小说里查找 hi，你可以使用正则表达式 **hi**。

这是最简单的正则表达式了，它可以精确匹配这样的字符串：由两个字符组成，前一个字符是 h, 后一个是 i。通常，处理正则表达式的工具会提供一个忽略大小写的选项，如果选中了这个选项，它可以匹配 **hi, HI, Hi, hI** 这四种情况中的任意一种。

不幸的是，很多单词里包含 **hi** 这两个连续的字符，比如：**him, history, high** 等等。用 **hi** 来查找的话，这里边的 **hi** 也会被找出来。如果要精确地查找 hi 这个单词的话，我们应该使用 **\bhi\b**。

**\b** 是正则表达式规定的一个特殊代码（好吧，某些人叫它**元字符**，meta character），代表着单词的开头或结尾，也就是单词的分界处。虽然通常英文的单词是由空格或标点符号或换行来分隔的，但是 **\b** 并不匹配这些单词分隔符中的任何一个，它只匹配一个位置。（如果需要更精确的说法，**\b** 匹配这样的位置：它的前一个字符和后一个字符不全是（一个是，一个不是或不存在）**|w**）

假如你要找的是 **hi** 后面不远处跟着一个 **Lucy**，你应该用 **\bhi\b.\*\bLucy\b**。这里，**.** 是另一个元字符，匹配除了换行符以外的任意字符。**\***同样是元字符，不过它代表的不是字符，也不是位置，而是数量——它指定\*前边的内容可以连续重复出现任意次以使整个表达式得到匹配。因此，**.\***连在一起就意味着任意数量的不包含换行的字符。现在 **\bhi\b.\*\bLucy\b** 的意思就很明显了：先是一个单词 hi, 然后是任意个任意字符(但不能是换行)，后是 Lucy 这段文字。

如果同时使用其它的一些元字符，我们就能构造出功能更强大的正则表达式。比如下面这个例子：

**0\d\d-\d\d\d\d\d\d\d\d** 匹配这样的字符串：以 0 开头，然后是两个数字，然后是一个连字号“-”，后是 8 个数字（也就是中国的电话号码。当然，这个例子只能匹配区号为 3 位的情形）。

这里的 **\d** 是一个新的元字符，匹配任意的数字（0，或 1，或 2，或……）。

-不是元字符，只匹配它本身——连字号。

为了避免那么多烦人的重复，我们也可以这样写这个表达式：**0\d{2}-\d{8}**。这里 **\d** 后面的 **{2}** (**{8}**) 的意思是前面 **\d** 必须连续重复匹配 2 次(8 次)。

## 5 测试正则表达式

如果你不觉得正则表达式很难读写的话，要么你是一个天才，要么，你不是地球人。正则表达式的语法很令人头疼，即使对经常使用它的人来说也是如此。由于难于读写，容易出错，所以很有必要创建一种工具来测试正则表达式。

由于在不同的环境下正则表达式的一些细节是不相同的，本教程介绍的是 Microsoft .Net 2.0 下正则表达式的行为，所以，我向你介绍一个 .Net 下的工具 [Regex Tester](#)。首先你确保已经安装了 [.Net Framework 2.0](#)，然后[下载 Regex Tester](#)。下载完后直接运行 RegexTester.exe 就可以了。

下面是 Regex Tester 运行时的截图：



## 6 元字符

现在你已经知道几个很有用的元字符了，如 `\b`, `.`, `*`, `\d`。当然还有更多的元字符可用，比如 `\s` 匹配任意的空白符，包括空格，制表符 (Tab)，换行符，中文全角空格等。`\w` 匹配字母或数字或下划线或汉等。

下面来试试更多的例子：

`\ba\w*\b` 匹配以字母 `a` 开头的单词——先是某个单词开始处 (`\b`)，然后是字母 `a`，然后是任意数量的字母或数字 (`\w*`)，后是单词结束处 (`\b`) (好吧，现在我们说说正则表达式里的单词是什么意思吧：就是几个连续的 `\w`。不错，这与学习英文时要背的成千上万个同名的东西的确关系不大)。

`\d+` 匹配 1 个或更多连续的数字。这里的 `+` 是和 `*` 类似的元字符，不同的是 `*` 匹配重复任意次 (可能是 0 次)，而 `+` 则匹配重复 1 次或更多次。`\b\w{6}\b` 匹配刚好 6 个字母/数字的单词。

表 1.常用的元字符	
代码	说明
.	<u>匹配除换行符以外的任意字符</u>
\w	<u>匹配字母或数字或下划线或汉字</u>
\s	<u>匹配任意的空白符</u>
\d	<u>匹配数字</u>
\b	<u>匹配单词的开始或结束</u>
^	<u>匹配字符串的开始</u>
\$	<u>匹配字符串的结束</u>

元字符<sup>^</sup>（和数字6在同一个键位上的符号）以及\$和\b有点类似，都匹配一个位置。<sup>^</sup>匹配你要用来查找的字符串的开头，\$匹配结尾。这两个代码在验证输入的内容时非常有用，比如一个网站如果要求你填写的QQ号必须为5位到12位数字时，可以使用：<sup>^</sup>\d{5,12}\$。

这里的{5,12}和前面介绍过的{2}是类似的，只不过{2}匹配只能不多不少重复2次，{5,12}则是重复的次数不能少于5次，不能多于12次，否则都不匹配。

因为使用了<sup>^</sup>和\$，所以输入的整个字符串都要用来和\d{5,12}来匹配，也就是说整个输入必须是5到12个数字，因此如果输入的QQ号能匹配这个正则表达式的话，那就符合要求了。

和忽略大小写的选项类似，有些正则表达式处理工具还有一个处理多行的选项。如果选中了这个选项，<sup>^</sup>和\$的意义就变成了匹配行的开始处和结束处。

## 7 字符转义

如果你想查找元字符本身的话，比如你查找<sup>^</sup>，或者\*，就出现了问题：你没法指定它们，因为它们会被解释成其它的意思。这时你就必须使用\来取消这些字符的特殊意义。因此，你应该使用\.<sup>^</sup>和\\*。当然，要查找\本身，你也得用\\。例如：www\.<sup>^</sup>unibetter\.<sup>^</sup>com匹配www.unibetter.com，c:\\Windows匹配c:\\Windows。

## 8 重复

你已经看过了前面的\*,+,{2},{5,12}这几个匹配重复的方式了。下面是正则表达式中所有的限定符（指定数量的代码，例如\*,{5,12}等）：

表 2.常用的限定符	
代码/语法	说明
*	<u>重复零次或更多次</u>
+	<u>重复一次或更多次</u>
?	<u>重复零次或一次</u>
{n}	<u>重复 n 次</u>
{n,}	<u>重复 n 次或更多次</u>
{n,m}	<u>重复 n 到 m 次</u>



下面是一些使用重复的例子:

- `Windows\d+`匹配 Windows 后面跟 1 个或更多数字
- `13\d{9}`匹配 13 后面跟 9 个数字(中国的手机号)
- `^\w+`匹配一行的第一个单词(或整个字符串的第一个单词, 具体匹配哪个意思得看选项设置)

## 9 字符类

要想查找数字, 字母或数字, 空白是很简单的, 因为已经有了对应这些字符集合的元字符, 但是如果你想匹配没有预定义元字符的字符集合(比如元音字母 a, e, i, o, u), 应该怎么办?

很简单, 你只需要在中括号里列出它们就行了, 像`[aeiou]`就匹配任何一个英文元音字母, `[.?!]`匹配标点符号(. 或?或!)(英文语句通常只以这三个标点结束)。我们也可以轻松地指定一个字符范围, 像`[0-9]`代表的含意与`\d`就是完全一致的: 一位数字, 同理`[a-z0-9A-Z_]`也完全等同于`\w`(如果只考虑英文的话)。

下面是一个更复杂的表达式: `\(?:\d{2}[-]?\d{8})`。这个表达式可以匹配几种格式的电话号码, 像 (010)88886666, 或 022-22334455, 或 02912345678 等。我们对它进行一些分析吧: 首先是一个转义字符`\`(, 它能出现 0 次或 1 次(`?`), 然后是一个 `0`, 后面跟着 2 个数字(`\d{2}`), 然后是)或-或空格中的一个, 它出现 1 次或不出现(`?`), 后是 8 个数字(`\d{8}`)。不幸的是, 它也能匹配 010)12345678 或 (022-87654321 这样的“不正确”的格式。要解决这个问题, 请在本教程的下面查找答案。

## 10 反义

有时需要查找不属于某个能简单定义的字符类的字符。比如想查找除了数字以外, 其它任意字符都行的情况, 这时需要用到反义:

表 3.常用的反义代码	
代码/语法	说明
<code>\W</code>	匹配任意不是字母, 数字, 下划线, 汉字的字符
<code>\S</code>	匹配任意不是空白符的字符
<code>\D</code>	匹配任意非数字的字符
<code>\B</code>	匹配不是单词开头或结束的位置
<code>[^x]</code>	匹配除了 x 以外的任意字符
<code>[^aeiou]</code>	匹配除了 aeiou 这几个字母以外的任意字符

例子:

- `\S+`匹配不包含空白符的字符串。



➤ `<a[^>]+>`匹配用尖括号括起来的以 a 开头的字符串。

## 11 替换

好了，现在终于到了解决 3 位或 4 位区号问题的时间了。正则表达式里的替换指的是有几种规则，如果满足其中任意一种规则都应该当成匹配，具体方法是用 `|` 把不同的规则分隔开。听不明白？没关系，看例子：

`0\d{2}-\d{8}|0\d{3}-\d{7}` 这个表达式能匹配两种以连字号分隔的电话号码：一种是三位区号，8 位本地号(如 010-12345678)，一种是 4 位区号，7 位本地号(0376-2233445)

`\(0\d{2}\)[- ]?\d{8}|0\d{2}[- ]?\d{8}` 这个表达式匹配 3 位区号的电话号码，其中区号可以用小括号括起来，也可以不用，区号与本地号间可以用连字号或空格间隔，也可以没有间隔。你可以试试用替换把这个表达式扩展成也支持 4 位区号的。

`\d{5}-\d{4}|\d{5}` 这个表达式用于匹配美国的邮政编码。美国邮编的规则是 5 位数字，或者用连字号间隔的 9 位数字。之所以要给出这个例子是因为它能说明一个问题：使用替换时，顺序是很重要的。如果你把它改成 `\d{5}|\d{5}-\d{4}` 的话，那么就只会匹配 5 位的邮编(以及 9 位邮编的前 5 位)。原因是匹配替换时，将会从左到右地测试每个分枝条件，如果满足了某个分枝的话，就不会去管其它的替换条件了。

`Windows98|Windows2000|WindoXP` 这个例子是为了告诉你替换不仅仅能用于两种规则，也能用于更多种规则。

## 12 分组

我们已经提到了怎么重复单个字符（直接在字符后面加上限定符就行了）；但如果想要重复多个字符又该怎么办？你可以用小括号来指定子表达式(也叫做分组)，然后你就可以指定这个子表达式的重复次数了，你也可以对子表达式进行其它一些操作(后面会有介绍)。

`(\d{1,3}\.){3}\d{1,3}` 是一个简单的 IP 地址匹配表达式。要理解这个表达式，请按下列顺序分析它：`\d{1,3}` 匹配 1 到 3 位的数字，`(\d{1,3}\.){3}` 匹配三位数字加上一个英文句号(这个整体也就是这个分组)重复 3 次，再加上一个一到三位的数字(`\d{1,3}`)。不幸的是，它也将匹配 256.300.888.999 这种不可能存在的 IP 地址(IP 地址中每个数字都不能大于 255。题外话，好像反恐 24 小时第三季的编剧不知道这一点，汗...)。如果能使用算术比较的话，或许能简单地解决这个问题，但是正则表达式中并不提供关于数学的任何功能，所以只能使用冗长的分组，选择，字符类来描述一个正确的 IP 地址：`((2[0-4]\d|25[0-5]|[01]?[0-9]\d)\.){3}(2[0-4]\d|25[0-5]|[01]?[0-9]\d)`。理解这个表达式的关键是理解 `2[0-4]\d|25[0-5]|[01]?[0-9]\d`，这里我就不细说了，你自己应该能分析得出来它的意义。

## 13 后向引用

使用小括号指定一个子表达式后，匹配这个子表达式的文本(也就是此分组捕获的内容)可以在表达式或其它程序中作进一步的处理。默认情况下，每个分组会自动拥有一个组号，规则是：从左向右，以分组的左括号为标志，第一个出现的分组的组号为 1，第二个为 2，以此类推。

后向引用用于重复搜索前面某个分组匹配的文本。例如，`\1` 代表分组 1 匹配的文本。难以理解？请看示例：

`\b(\w+)\b\s+\1\b` 可以用来匹配重复的单词，像 go go, kitty kitty。首先是一个单词，也就是单词开始处和结束处之间的多于一个的字母或数字(`\b(\w+)\b`)，然后是 1 个或几个空白符(`\s+`)，后是前面匹配的那个单词(`\1`)。

你也可以自己指定子表达式的组名。要指定一个子表达式的组名，请使用这样的语法：  
(`?<Word>\w+`) (或者把尖括号换成单引号也行：`(?'Word'\w+)`)，这样就把 `\w+` 的组名指定为 `Word` 了。要反向引用这个分组捕获的内容，你可以使用 `\k<Word>`，所以上一个例子也可以写成这样：

`\b(?<Word>\w+)\b\s+\k<Word>\b`。

使用小括号的时候，还有很多特定用途的语法。下面列出了 常用的一些：

表 4.分组语法	
捕获	
<code>(exp)</code>	匹配 exp,并捕获文本到自动命名的组里
<code>(?&lt;name&gt;exp)</code>	匹配 exp,并捕获文本到名称为 name 的组里，也可以写成('name'exp)
<code>(?:exp)</code>	匹配 exp,不捕获匹配的文本，也不给此分组分配组号
零宽断言	
<code>(?=exp)</code>	匹配 exp 前面的位置
<code>(?&lt;=exp)</code>	匹配 exp 后面的位置
<code>(?!exp)</code>	匹配后面跟的不是 exp 的位置
<code>(?&lt;!exp)</code>	匹配前面不是 exp 的位置
注释	
<code>(?#comment)</code>	这种类型的组不对正则表达式的处理产生任何影响，用于提供注释让人阅读

我们已经讨论了前两种语法。第三个 `(?:exp)` 不会改变正则表达式的处理方式，只是这样的组匹配的内容不会像前两种那样被捕获到某个组里面。

## 14 零宽断言

接下来的四个用于查找在某些内容(但并不包括这些内容)之前或之后的东西，也就是说它们像 `\b`, `^`, `$` 那样用于指定一个位置，这个位置应该满足一定的条件(断言)，因此它们也被称为零宽断言。好还是拿例子来说明吧：

(?=exp) 也叫零宽度正预测先行断言, 它断言自身出现的位置的后面能匹配表达式 exp。比如

`\b\w+(?=ing\b)`, 匹配以 ing 结尾的单词的前面部分 (除了 ing 以外的部分), 如查找 I'm singing while you're dancing. 时, 它会匹配 sing 和 danc。

(?<=exp) 也叫零宽度正回顾后发断言, 它断言自身出现的位置的前面能匹配表达式 exp。比如

`(?<=\bre)\w+\b` 会匹配以 re 开头的单词的后半部分 (除了 re 以外的部分), 例如在查找 reading a book 时, 它匹配 ading。假如你想要给一个很长的数字中每三位间加一个逗号 (当然是从右边加起了), 你可以这样查找需要在前面和里面添加逗号的部分: `((?<=\d)\d{3})*\b`, 用它对 1234567890 进行查找时结果是 234567890。

下面这个例子同时使用了这两种断言: `(?<=\s)\d+(?=\s)` 匹配以空白符间隔的数字 (再次强调, 不包括这些空白符)。

## 15 负向零宽断言

前面我们提到过怎么查找不是某个字符或不在某个字符类里的字符的方法 (反义)。但是如果我们只是想要确保某个字符没有出现, 但并不想去匹配它时怎么办? 例如, 如果我们想查找这样的单词--它里面出现了字母 q, 但是 q 后面跟的不是字母 u, 我们可以尝试这样:

`\b\w*q[^u]\w*\b` 匹配包含后面不是字母 u 的字母 q 的单词。但是如果多做测试 (或者你思维足够敏锐, 直接就观察出来了), 你会发现, 如果 q 出现在单词的结尾的话, 像 Iraq, Benq, 这个表达式就会出错。这是因为 `[^u]` 总要匹配一个字符, 所以如果 q 是单词的 后一个字符的话, 后面的 `[^u]` 将会匹配 q 后面的单词分隔符 (可能是空格, 或者是句号或其它的什么), 后面的 `\w*\b` 将会匹配下一个单词, 于是 `\b\w*q[^u]\w*\b` 就能匹配整个 Iraq fighting。负向零宽断言能解决这样的问题, 因为它只匹配一个位置, 并

不消费任何字符。现在, 我们可以这样来解决这个问题:

`\b\w*q(?:u)\w*\b`。

零宽度负预测先行断言 `(?!exp)`, 断言此位置的后面不能匹配表达式

exp。例如: `\d{3}(?!\d)` 匹配三位数字, 而且这三位数字的后面不能是数字; `\b(?:!abc)\w+\b` 匹配不包含连续字符串 abc 的单词。

同理, 我们可以用 `(?<!exp)`, 零宽度正回顾后发断言来断言此位置的前面不能匹配表达式 exp:

`(?<![a-z])\d{7}` 匹配前面不是小写字母的七位数字。

一个更复杂的例子：`(?<=<(\w+)>).*?(?=<\1>)`匹配不包含属性的简单 HTML 标签内里的内容。`(?<(\w+)>)`指定了这样的前：被尖括号括起来的单词(比如可能是`<b>`)，然后是`*`(任意的字符串)，后是一个`(?=<\1>)`。注意后里的`\1`，它用到了前面提过的字符转义；`\1`则是一个反向引用，引用的正是捕获的第一组，前面的`(\w+)`匹配的内容，这样如果前 实际上是`<b>`的话，后 就是`</b>`了。整个表达式匹配的是`<b>`和`</b>`之间的内容(再次提醒，不包括前`<b>`和后`</b>`本身)。

## 16 注释

小括号的另一种用途是能过语法`(?#comment)`来包含注释。

例如：`2[0-4]\d(?#200-249)|25[0-5](?#250-255)|[01]?[0-9]\d(?#0-199)`。

要包含注释的话，好是启用“忽略模式里的空白符”选项，这样在编写表达式时能任意的添加空格，Tab，换行，而实际使用时这些都将忽略。启用这个选项后，在`#`后面到这一行结束的所有文本都将被当成注释忽略掉。

例如，我们可以前面的一个表达式写成这样：

<code>(?&lt;=</code>	# 断言要匹配的文本的前
<code>&lt;(\w+)&gt;</code>	# 查找尖括号括起来的字母或数字(即 HTML/XML 标签)
<code>)</code>	# 前 结束
<code>.*</code>	# 匹配任意文本
<code>(?=&lt;</code>	# 断言要匹配的文本的后
<code>&lt;\1&gt;</code>	# 查找尖括号括起来的内容：前面是一个 <code>"/"</code> ，后面是先前捕获的标签
<code>)</code>	# 后 结束

### 贪婪与懒惰

当正则表达式中包含能接受重复的限定符时，通常的行为是（在使整个表达式能得到匹配的前提下）匹配尽可能多的字符。考虑这个表达式：`a.*b`，它将会匹配 长的以 a 开始，以 b 结束的字符串。如果用它来搜索 `aabab` 的话，它会匹配整个字符串 `aabab`。这被称为贪婪匹配。有时，我们更需要懒惰匹配，也就是匹配尽可能少的字符。前面给出的限定符都可以被转化为懒惰匹配模式，只要在其后面加上一个问号`?`。这样`.*?`就意味着匹配任意数量的重复，但是在能使整个匹配成功的前提下使用 少的重复。现在看看懒惰版的例子吧：

`a.*?b` 匹配 短的，以 a 开始，以 b 结束的字符串。如果把它应用于 `aabab` 的话，它会匹配 `aab` 和 `ab`

（为什么第一个匹配是 `aab` 而不是 `ab`？简单地说，因为正则表达式有另一条规则，比懒惰 / 贪婪规则的优先级更高：先开始的匹配 有 大的优先权——The Match That Begins Earliest Wins）。

表 5.懒惰限定符	
<code>*?</code>	重复任意次，但尽可能少重复
<code>+</code>	重复 1 次或更多次，但尽可能少重复

??	重复 0 次或 1 次, 但尽可能少重复
{n,m}?	重复 n 到 m 次, 但尽可能少重复
{n,}?	重复 n 次以上, 但尽可能少重复

## 17 处理选项

上面介绍了几个选项如忽略大小写, 处理多行等, 这些选项能用来改变处理正则表达式的方式。下面是 .Net 中常用的正则表达式选项:

表 6.常用的处理选项	
名称	说明
IgnoreCase (忽略大小写)	匹配时不区分大小写。
Multiline (多行模式)	更改^和\$的含义, 使它们分别在任意一行的行首和行尾匹配, 而不仅仅在整个字符串的开头和结尾匹配。(在此模式下,\$的精确含意是:匹配\n 之前的位置以及字符串结束前的位置.)
Singleline (单行模式)	更改.的含义, 使它与每一个字符匹配 (包括换行符\n)。
IgnorePatternWhitespace (忽略空白)	忽略表达式中的非转义空白并启用由#标记的注释。
RightToLeft (从右向左查找)	匹配从右向左而不是从左向右进行。
ExplicitCapture (显式捕获)	仅捕获已被显式命名的组。
ECMAScript (JavaScript 兼容模式)	使表达式的行为与它在 JavaScript 里的行为一致。

一个经常被问到的问题是: 是不是只能同时使用多行模式和单行模式中的一种? 答案是: 不是。这两个选项之间没有任何关系, 除了它们的名字比较相似 (以至于让人感到疑惑) 以外。

## 18 平衡组/递归匹配

**注意:** 这里介绍的平衡组语法是由 .Net Framework 支持的; 其它语言 / 库不一定支持这种功能, 或者支持此功能但需要使用不同的语法。

有时我们需要匹配像 `( 100 * ( 50 + 15 ) )` 这样的可嵌套的层次性结构, 这时简单地使用 `\(.+\)` 则只会匹配到 左边的左括号和 右边的右括号之间的内容(这里我们讨论的是贪婪模式, 懒惰模式也有下面的问题)。

假如原来的字符串里的左括号和右括号出现的次数不相等，比如 ( 5 / ( 3 + 2 ) ) )，那我们的匹配结果里两者的个数也不会相等。有没有办法在这样的字符串里匹配到 长的，配对的括号之间的内容呢？

为了避免 (和\ (把你的大脑彻底搞糊涂，我们还是用尖括号代替圆括号吧。现在我们的问题变成了如何把 xx <aa <bbb> <bbb> aa> yy 这样的字符串里， 长的配对的尖括号内的内容捕获出来？

这里需要用到以下的语法构造

- (? 'group' ) 把捕获的内容命名为 group, 并压入堆栈
- (? ' -group' ) 从堆栈上弹出 后压入堆栈的名为 group 的捕获内容，如果堆栈本来为空，则本分组的匹配失败
- (? (group) yes | no) 如果堆栈上存在以名为 group 的捕获内容的话，继续匹配 yes 部分的表达式，否则继续匹配 no 部分
- (?!) 零宽负向先行断言，由于没有后 表达式，试图匹配总是失败

如果你不是一个程序员（或者你是一个对堆栈的概念不熟的程序员），你就这样理解上面的三种语法吧：第一个就是在黑板上写一个 "group"，第二个就是从黑板上擦掉一个"group"，第三个就是看黑板上写的还有没有"group"，如果有就继续匹配 yes 部分，否则就匹配 no 部分。我们需要做的是每碰到了左括号，就在黑板上写一个"group"，每碰到一个右括号，就擦掉一个，到了 后就看看黑板上还有没有——如果有那就证明左括号比右括号多，那匹配就应该失败。

<	# 外层的左括号
[^<>]*	# 外层的左括号后面的不是括号的内容
(	
(	
(?'Open'<)	#碰到了左括号，在黑板上写一个"Open"
[^<>]*	#匹配左括号后面的不是括号的内容
) +	
(	
(?'-Open'>)	#碰到了右括号，擦掉一个"Open"
[^<>]*	#匹配右括号后面不是括号的内容
) +	
) *	
(?(Open)(?!))	#在遇到外层的右括号前面，判断黑板上还有没有没擦掉的"Open"；如果还有，则匹配失败
>	# 外层的右括号

平衡组的一个 常见的应用就是匹配 HTML, 下面这个例子可以匹配嵌套的<div>标签:

<div[^>]\*>[^<>]\*(((?'Open'<div[^>]\*>)[^<>]\*+((?'-Open'</div>)[^<>]\*+)\*?(?(Open)(?!))</div>



## 19 还有些什么东西没提到

我已经描述了构造正则表达式的大量元素，还有一些我没有提到的东西。下面是未提到的元素的列表，包含语法和简单的说明。你可以在网上找到更详细的参考资料来学习它们—当你需要用到它们的时候。如果你安装了 MSDN Library, 你也可以在里面找到关于 .net 下正则表达式详细的文档。

表 7.尚未详细讨论的语法	
<code>\a</code>	报警字符(打印它的效果是电脑嘀一声)
<code>\b</code>	通常是单词分界位置，但如果在字符类里使用代表退格
<code>\t</code>	制表符，Tab
<code>\r</code>	回车
<code>\v</code>	竖向制表符
<code>\f</code>	换页符
<code>\n</code>	换行符
<code>\e</code>	Escape
<code>\0nn</code>	ASCII 代码中八进制代码为 <code>nn</code> 的字符
<code>\xnn</code>	ASCII 代码中十六进制代码为 <code>nn</code> 的字符
<code>\unnnn</code>	Unicode 代码中十六进制代码为 <code>nnnn</code> 的字符
<code>\cN</code>	ASCII 控制字符。比如 <code>\cC</code> 代表 Ctrl+C
<code>\A</code>	字符串开头(类似 <code>^</code> ，但不受处理多行选项的影响)
<code>\Z</code>	字符串结尾或行尾(不受处理多行选项的影响)
<code>\z</code>	字符串结尾(类似 <code>\$</code> ，但不受处理多行选项的影响)
<code>\G</code>	当前搜索的开头
<code>\p{name}</code>	Unicode 中命名为 <code>name</code> 的字符类，例如 <code>\p{IsGreek}</code>
<code>(?&gt;exp)</code>	贪婪子表达式
<code>(?&lt;x&gt;-&lt;y&gt;exp)</code>	平衡组
<code>(?im-nsx:exp)</code>	在子表达式 <code>exp</code> 中改变处理选项
<code>(?im-nsx)</code>	为表达式后面的部分改变处理选项
<code>(?(exp)yes no)</code>	把 <code>exp</code> 当作零宽正向先行断言，如果在这个位置能匹配，使用 <code>yes</code> 作为此组的表达式；否则使用 <code>no</code>
<code>(?(exp)yes)</code>	同上，只是使用空表达式作为 <code>no</code>
<code>(?(name)yes no)</code>	如果命名为 <code>name</code> 的组捕获到了内容，使用 <code>yes</code> 作为表达式；否则使用 <code>no</code>
<code>(?(name)yes)</code>	同上，只是使用空表达式作为 <code>no</code>

## 20 联系作者



好吧, 我承认, 我骗了你, 读到这里你肯定花了不少 30 分钟. 相信我, 这是我的错, 而不是因为你太笨. 我之所以说“30 分钟”, 是为了让你有信心, 有耐心继续下去. 既然你看到了这里, 那证明我的阴谋成功了. 上这种当的滋味还不错吧?


要投诉我, 或者觉得我其实可以做得更好, 或者有任何其它问题, 欢迎来 [dearchao 的博客](#) 进行讨论.

## 21 一些我认为你可能已经知道的术语的参考

- **字符:** 程序处理文字时基本的单位, 可能是字母, 数字, 标点符号, 空格, 换行符, 汉字等等。
- **字符串:** 0 个或更多个字符的序列。 文本 文字, 字符串。
- **匹配:** 符合规则, 检验是否符合规则, 符合规则的部分。
- **断言:** 声明一个应该为真的事实。只有当断言为真时才会对正则表达式继续进行匹配。

## 22 网上的资源及本文参考文献

- [微软的正则表达式教程](#)
- [System.Text.RegularExpressions.Regex 类\(MSDN\)](#)
- [专业的正则表达式教学网站\(英文\)](#)
- [关于.Net 下的平衡组的详细讨论 \(英文\)](#)
- [Mastering Regular Expressions \(Second Edition\)](#)
- [Validated XHTML 1.0 Strict](#)
- [Validated CSS 2.1](#)
- [推荐使用 Mozilla FireFox 浏览](#)



学习分享，共同成长

- 
- 欢迎在文章下评论留言
  - 其它联系方式:
  - 邮箱: [whs83@163.com](mailto:whs83@163.com)
  - 个人网站: <https://HuaiSheng.Wang>
- 

“感谢阅读”

@OutMan 2017 年 10 月